

机器学习实验指导手册

线性回归模型

一、实验目的

- 掌握线性回归模型的数学原理与实现方法
- 理解最小二乘法与梯度下降算法的应用
- 学会使用 Python 实现线性回归模型
- 掌握模型评估与结果分析方法

二、实验原理

1. 数学模型

假设函数：

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n = \theta^T X$$

其中： $\theta = \langle \theta_0, \theta_1, \dots, \theta_n \rangle$; $X = \langle x_1, x_2, \dots, x_n \rangle$

目标函数（均方误差）：

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

基于训练集 E ： $\{(x^{(i)}, y^{(i)}), i = 1 \dots m\}$

2. 参数求解

解析解（闭式解）：

$$\theta = (X^T X)^{-1} X^T y$$

梯度下降法：

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

三、实验步骤

1. 数据准备

使用 sklearn 糖尿病数据集：

```
python
from sklearn.datasets import load_diabetes
data = load_diabetes()
X, y = data.data, data.target
```

2. 数据预处理

```
python
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split

# 标准化
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# 划分数据集
X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size=0.2, random_state=42)
```

3. 模型实现

解析解实现：

```
python
import numpy as np

# 添加偏置项
X_b = np.c_[np.ones((X_train.shape[0], 1)), X_train]

# 计算闭式解
theta_best = np.linalg.pinv(X_b.T.dot(X_b)).dot(X_b.T).dot(y_train)

# 预测函数
def predict(X):
    X_b = np.c_[np.ones((X.shape[0], 1)), X]
    return X_b.dot(theta_best)
```

梯度下降实现：

```
python
def gradient_descent(X, y, learning_rate=0.01, n_iters=1000):
    m = X.shape[0]
    X_b = np.c_[np.ones((m, 1)), X]
    theta = np.random.randn(X_b.shape[1], 1)

    for _ in range(n_iters):
        gradients = 2/m * X_b.T.dot(X_b.dot(theta) - y.reshape(-1,1))
        theta -= learning_rate * gradients
    return theta
```

4. 模型评估

```
python
from sklearn.metrics import mean_squared_error, r2_score

# 解析解评估
y_pred = predict(X_test)
print(f'MSE: {mean_squared_error(y_test, y_pred):.2f}')
print(f'R²: {r2_score(y_test, y_pred):.2f}')
```

```
# 可视化结果
import matplotlib.pyplot as plt
plt.scatter(y_test, y_pred)
plt.plot([min(y_test), max(y_test)], [min(y_test), max(y_test)], 'r--')
plt.xlabel('True Values')
plt.ylabel('Predictions')
plt.show()
```

四、实验要求

必做任务

1. 实现解析解和梯度下降两种方法；
2. 比较不同学习率（0.001, 0.01, 0.1）对梯度下降的影响；
3. 绘制损失函数下降曲线；
4. 分析两种方法的精度差异；

扩展任务

1. 尝试不同特征组合对结果的影响；
2. 使用其他评估指标（平均绝对误差 MAE 等）；